FPT Education

FPT POLYTECHNIC

cdio™

Conceive Design Implement Operate

Bài 1: Giới Thiệu và Làm Sạch

www.poly.edu.vn

AGENDA

- Hiểu vai trò tiền xử lý
- Vấn đề dữ liệu thực tế
- Phương pháp xử lý
- Thực hành

1. Vai Trò Của Tiền Xử Lý

70–80% thời gian dành cho xử lý dữ liệu

Theo khảo sát của Kaggle (2022) và Forbes, Data Scientist dành:

- ~79% thời gian cho xử lý, làm sạch và chuẩn hóa dữ liệu
- Chỉ ~20% thời gian cho huấn luyện mô hình và đánh giá

Nghiên cứu của IBM (2017):

- Data cleansing chiếm 60–80% thời gian trong các dự án AI/ML

Dữ liệu bẩn = Mô hình kém chính xác

Ảnh hưởng tiêu cực của dữ liệu không được xử lý:

- Giảm độ chính xác mô hình (Accuracy, RMSE, MAE…)
- Dễ gây overfitting/underfitting
- Kết quả thiếu tin cậy → quyết định sai lầm

Ví dụ: Dự đoán giá nhà

Diện tích	Số phòng	Phường	Giá (VNĐ)
120 m^2	3	P1	5,200,000,000
(thiếu)	2	P2	4,000,000,000
85m2	3	(thiếu)	3,800,000,000
150 m2	4	P7	“6800” (lỗi định dạng)
150 m^2	4	P7	-100,000,000 (giá âm)

Hậu quả nếu không xử lý:

- Dự đoán lệch hàng trăm triệu đến hàng tỷ đồng
- Mô hình không học được mối quan hệ thực

2. Vấn Đề Thường Gặp

2.1 Thiếu dữ liệu (Missing Data)

Một số trường thông tin bị bỏ trống do lỗi nhập liệu, thu thập không đầy đủ hoặc lỗi hệ thống. -> Làm giảm độ tin cậy mô hình, mất thông tin quan trọng → Sai lệch dự báo.

Ví dụ:

Diện tích (m^2)	Số phòng	Giá (tỷ đồng)
85	2	3.8
NaN	3	4.2
120	*NaN*	5.0
100	2	*NaN*

2.2 Dữ liệu lỗi (Invalid / Incorrect Data)

Dữ liệu có giá trị sai phạm logic hoặc không hợp lý về mặt thực tế.

-> Gây sai kết quả, làm hỏng quá trình huấn luyện.

Ví dụ:

Diện tích (m^2)	Giá (tỷ đồng)
0	4.0
150	-5.2
90	3.5
-75	2.8

2.3 Dữ liệu nhiễu (Noise)

Dữ liệu bị nhiễu do nhập sai, đo lường sai, hoặc lỗi hệ thống.

-> Tăng sai số, làm mô hình khó học được quy luật thực, dễ overfitting.

Ví dụ:

Diện tích (m^2)	Giá (tỷ đồng)
90	3.5
100	3.8
95	4.0
100	**12.0** (nhiễu)

2.4 Dữ liệu không đồng nhất (Inconsistency)

Dữ liệu có cùng ý nghĩa nhưng biểu diễn khác nhau về format, đơn vị, kiểu. -> Gây lỗi khi phân tích, mô hình không hiểu được các giá trị tương đương.

Ví dụ:

Diện tích (m^2)	Giá (tỷ đồng)
90	3.5
100	3.8
95	4.0
100	**12.0** (nhiễu)

TỔNG HỢP - SO SÁNH

Loại vấn đề	Ảnh hưởng đến mô hình
Thiếu dữ liệu	Giảm chất lượng dự báo, độ tin cậy thấp
Dữ liệu lỗi	Gây ra kết quả sai hoặc không hợp lý
Dữ liệu nhiễu	Tăng sai số, dễ gây overfitting
Dữ liệu không đồng nhất	Khó xử lý, ảnh hưởng khả năng học của mô hình

3. Phương Pháp Xử Lý

3. PHƯƠNG PHÁP XỬ LÝ

3.1 Các bước xử lý cơ bản

Khám phá dữ liệu
→ thống kê, trực quan hóa, hiểu cấu trúc

Phát hiện lỗi / vấn đề
→ thiếu, sai lệch, trùng lặp, không hợp lý

Làm sạch dữ liệu
→ xử lý missing, loại outliers, chuẩn hóa

Lưu trữ dữ liệu đã xử lý
→ để sử dụng cho mô hình hóa & phân tích

3.2 Thiếu dữ liệu - Nguyên nhân & Phát hiện

Nguyên nhân phổ biến:

- Nhập liệu thiếu
- Mất dữ liệu trong quá trình thu thập
- Sensor/reporting failure

Phát hiện:

- Hàm isnull() trong Python/Pandas
- Đếm số lượng giá trị thiếu theo cột (df.isnull().sum())
- Trực quan hóa với heatmap (Seaborn)

3.2 Thiếu dữ liệu - Cách xử lý cơ bản

1. Loại bỏ (Deletion)
   - Bỏ dòng/cột chứa nhiều giá trị thiếu
   - Chỉ dùng khi dữ liệu đủ lớn

2. Điền giá trị (Imputation)
   - Mean / Median / Mode
   - Ưu tiên dùng median nếu dữ liệu có outlier
   - Với biến phân loại → dùng mode

3.2 Thiếu dữ liệu - Cách xử lý nâng cao

Các phương pháp hiện đại:

- KNN Imputation: Điền giá trị dựa vào các hàng tương đồng gần nhất
- MICE (Multiple Imputation by Chained Equations)
- Machine Learning-based Prediction: Huấn luyện mô hình dự đoán cho các giá trị bị thiếu

Các thư viện hỗ trợ: fancyimpute, sklearn.impute, statsmodels

3.3 Xử lý Dữ liệu lỗi

Ví dụ lỗi thường gặp:

- Diện tích = 0
- Giá nhà âm
- Tuổi = 150

Cách xử lý:

- Kiểm tra phạm vi hợp lý (min/max values)
- Chuẩn hóa đơn vị (vd: m^2 vs cm^2)
- Loại bỏ hoặc đánh dấu bản ghi lỗi để xử lý sau

3.4 Xử lý Dữ liệu nhiễu (Noise)

Nguyên nhân:

- Lỗi nhập tay
- Sai số do thiết bị đo hoặc cảm biến

Phương pháp xử lý:

- Binning: gom nhóm giá trị gần nhau
- Smoothing: làm mượt giá trị bằng trung bình trượt
- Regression smoothing: dùng mô hình hồi quy để tái ước lượng

3.5 Xử lý Dữ liệu không đồng nhất

Cùng 1 giá trị, nhiều cách biểu diễn

- "3 phòng" vs "3p"
- "TP.HCM", "HCM", "Ho Chi Minh"

Giải pháp:

- Chuẩn hóa dữ liệu text: lowercase, xóa ký tự đặc biệt
- Chuyển đổi kiểu dữ liệu: text → số, ngày → chuẩn ISO
- Ánh xạ giá trị (mapping) để thống nhất định danh

3.6. So sánh trước và sau

Trực quan Histogram / Boxplot trước & sau xử lý
-> Hiển thị sự cải thiện phân phối dữ liệu

Đếm số lượng bản ghi hợp lệ
Ví dụ: Từ 85% → 98%

4. Thực Hành Làm Sạch

4.1 Chuẩn bị

Mục tiêu:

- Làm quen với tập dữ liệu *house_prices_slide_1.csv*
- Thực hành khám phá dữ liệu, phát hiện một số vấn đề thường gặp

Công cụ sử dụng:

- Jupyter Notebook/Google Colab + Python
- Thư viện: pandas, numpy, matplotlib

4.2 Khám phá dữ liệu

Nạp dữ liệu

```
import pandas as pd
df = pd.read_csv("house_prices.csv")
df.head()
```

Các phép thống kê cơ bản

- `df.shape` -> Kích thước dữ liệu
- `df.info()` -> Kiểu dữ liệu và giá trị thiếu
- `df.describe()` -> Thống kê số liệu với cột số

4.2 Khám phá dữ liệu

Hỏi đáp

1. Cột nào có nhiều missing?
2. Cột nào có giá trị bất thường?

4.3 Kiểm tra giá trị thiếu

Đếm số lượng NaN theo cột:

- `df.isnull().sum()`

Kiểm tra cụ thể một cột:

- `df["area"].isnull().sum()`
- `df["rooms"].isnull().sum()`

4.3 Kiểm tra giá trị thiếu

Hỏi đáp

1. Nên xử lý hay loại bỏ?
2. Cột nào ảnh hưởng mô hình nhiều hơn?

4.4 Xử lý giá trị thiếu

Cách 1: Loại bỏ dòng

- `df_dropped = df.dropna()`

Cách 2: Điền giá trị mean/median

- `df["room_median"] = df["rooms"].fillna(df["rooms"].median(), inplace=False)`
- `df["room_mean"] = df["rooms"].fillna(df["rooms"].median(), inplace=False)`

4.4 Xử lý giá trị thiếu

So sánh phân phối

- `df["room_median"].hist(bins=10)`
- `df["room_mean"].hist(bins=10)`
- `df_dropped["rooms"].hist(bins=10)`

4.5 Phát hiện dữ liệu lỗi

Kiểm tra giá trị sai

- `df[df["area"] == "0"]`
- `df[df["price"] < 0]`

Hỏi đáp

1. Giá trị như nào là hợp lệ?
2. Có nên sửa hay loại bỏ?

4.6 Chuyển đổi và làm sạch diện tích

Chuyển từ "85 m²" → 85 (float)

```
df["area_clean"] = df["area"].str.replace(" m²",
"", regex=False)

df["area_clean"] = pd.to_numeric(df["area_clean"],
errors='coerce')
```

4.7 Phát hiện dữ liệu nhiễu

Cách 1: Sử dụng thống kê

- Z-score: điểm dữ liệu có độ lệch chuẩn lớn
- IQR (Interquartile Range): điểm nằm ngoài [Q1 - 1.5×IQR, Q3 + 1.5×IQR]

Cách 2: Dùng biểu đồ để "nhìn thấy" dữ liệu nhiễu:

- Boxplot: hiệu quả để phát hiện outlier
- Scatter plot: nhìn thấy điểm "lệch" khỏi xu hướng
- Line plot: với dữ liệu theo thời gian → phát hiện spikes

```
import seaborn as sns
sns.boxplot(x=df["price"])  # Xem giá nào "quá cao" hoặc "quá thấp"
```

4.7 Phát hiện dữ liệu nhiễu

Cách 1: Sử dụng thống kê

Cách 2: Trực quan hóa

Cách 3: Dựa trên kiến thức nghiệp vụ

Trường	Điều kiện lỗi
area	= 0 hoặc > 1000 m^2
price	< 1 triệu hoặc > 100 tỷ
rooms	> 10 hoặc < 1

4.8 Chuẩn hóa dữ liệu text

Chuẩn hóa địa điểm -> viết thường

- *TP. Ho Chi Minh* vs *tp. ho chi minh*
- *HCM* vs *hcm*

<u>Hỏi đáp</u>

Làm sao để ánh xạ *tp. ho chi minh -> hcm?*

FPT Education

FPT POLYTECHNIC

THANK YOU