FPT Education

FPT POLYTECHNIC

cdio™

Conceive Design Implement Operate

Bài 2: Phát Hiện và Xử Lý Ngoại Lệ

www.poly.edu.vn

AGENDA

- Khái niệm ngoại lệ
- Nguyên nhân ngoại lệ
- Phương pháp phát hiện
- Thực hành

1. Khái Niệm Ngoại Lệ

1.1 Định nghĩa

- Ngoại lệ là những giá trị khác biệt rõ rệt so với phần lớn dữ liệu còn lại.
- Thường là những điểm dữ liệu rất lớn hoặc rất nhỏ một cách bất thường.

Ví dụ:

- Một căn nhà có giá 1 đồng hoặc 1.000 tỷ đồng trong khi phần lớn chỉ vài tỷ.
- Diện tích nhà thông thường khoảng 50–200 m^2, nhưng có căn chỉ 1 m^2 hoặc 5.000 m^2.

1.1 Định nghĩa (Ví dụ)

- Lớp có điểm kiểm tra như sau: [6, 7, 6.5, 7.5, 10, 0]

→ 0 và 10 đều là ngoại lệ (một bạn học siêu giỏi, một bạn... quên nộp bài)

- Sinh viên mỗi tháng tiêu ~2–3 triệu

→ Có bạn tiêu 50 triệu/tháng → Ngoại lệ (hoặc rich kid)

- Mọi người đều tặng bạn món quà giá ~200k, có một người tặng ô tô

→ Quá khác biệt → ngoại lệ

1.2 Ảnh hưởng của ngoại lệ

- Làm lệch trung bình, khiến các thống kê không phản ánh đúng dữ liệu.
- Tăng phương sai, làm dữ liệu "loãng", mất tính ổn định.
- Ảnh hưởng đến mô hình học máy (ML):
  - Mô hình học sai xu hướng chung.
  - Gây overfitting hoặc kết quả dự đoán thiếu chính xác.

1.2 Ảnh hưởng của ngoại lệ (Ví dụ)

- Trong một lớp học, cả lớp nặng trung bình 50–60 kg, riêng một bạn là... siêu nhân nặng 300 kg → Trung bình cân nặng lớp là ~90 kg → mất ý nghĩa thực tế.

- Báo cáo: "Giá nhà trung bình là 100 tỷ" (do 2 căn siêu đắt chen vào) → Doanh nghiệp nghĩ thị trường cao cấp là xu hướng → ra quyết định sai.

- Huấn luyện AI chơi cờ caro. Trong dữ liệu có vài ván mà người thua lại được tính là thắng (do nhập sai) → AI sẽ học sai chiến thuật và thua suốt.

1.3 Ngoại lệ trong bài toán giá nhà

Một số ví dụ thực tế:

- Nhà có diện tích 0 m^2 nhưng vẫn có thông tin đầy đủ về địa chỉ, giá và số phòng → Lỗi nhập liệu

- Căn nhà ở quận bình thường, diện tích 100 m^2 nhưng giá rao bán là 500 tỷ

→ Có thể là:

Gõ sai số 0 (50 tỷ → 500 tỷ)

Người bán... "rất lạc quan"

1.3 Ngoại lệ trong bài toán giá nhà

Một số ví dụ thực tế:

- Nhà có 50 phòng ngủ → Khả năng cao là nhập nhầm, hoặc là khách sạn/chung cư mini.

- Một căn nhà siêu nhỏ (10 m^2) được rao bán với giá cực cao (50 tỷ) → Có thể:

Ở vị trí siêu đắc địa (mặt tiền trung tâm TP HCM)

Hoặc sai lệch đơn vị (m^2 vs ft^2)

2. Nguyên Nhân & Cách Xử Lý

2.1 Nguyên nhân

2.1.1 Lỗi nhập liệu

"Ngoại lệ xuất hiện không phải vì dữ liệu sai, mà vì người nhập... hơi sai!"

- Ví dụ 1 – Thiếu dấu chấm phân cách

Nhập giá nhà: 100000000000

→ Người nhập quên dấu ., thay vì 100 tỷ, dữ liệu lại thành 100.000 tỷ

→ Ngoại lệ quá lớn!

2.1 Nguyên nhân

2.1.1 Lỗi nhập liệu

"Ngoại lệ xuất hiện không phải vì dữ liệu sai, mà vì người nhập... hơi sai!"

- Ví dụ 2 – Copy nhầm từ file khác

Copy từ file Excel bị lệch cột:

- Cột diện tích: "90 m²"
- Copy nhầm sang cột số phòng → "Số phòng = 90"

  → Ngoại lệ

2.1 Nguyên nhân

2.1.1 Lỗi nhập liệu

"Ngoại lệ xuất hiện không phải vì dữ liệu sai, mà vì người nhập... hơi sai!"

- Ví dụ 3 – Gõ nhầm đơn vị

Diện tích nhà: thực tế là 80 m^2, nhưng gõ nhầm thành 8000 m^2

→ Nhà từ "phòng trọ" thành sân bay

2.1 Nguyên nhân

2.1.1 Lỗi nhập liệu

"Ngoại lệ xuất hiện không phải vì dữ liệu sai, mà vì người nhập... hơi sai!"

- Gõ sai số khi nhập tay (ví dụ: thêm số 0, thiếu dấu chấm).
- Copy-paste nhầm ô dữ liệu.
- Đơn vị không thống nhất (m^2 vs ha, triệu vs tỷ).

2.1.2 Đặc thù thực tế

"Không phải ngoại lệ nào cũng sai – có những giá trị rất khác biệt là do cuộc sống vốn đã khác biệt!"

- Ví dụ 1 – Biệt thự siêu sang

Căn nhà mặt hồ Tây, diện tích 3000 m², giá 250 tỷ
→ Ngoại lệ nhưng hợp lý vì là bất động sản siêu cao cấp

- Ví dụ 2 – Nhà thừa kế

Căn hộ được tặng thừa kế, bán lại với giá rẻ bất thường vì cần tiền gấp
→ Ngoại lệ xuất hiện vì yếu tố cảm tính của con người, không do lỗi kỹ thuật

2.1.2 Đặc thù thực tế

"Không phải ngoại lệ nào cũng sai – có những giá trị rất khác biệt là do cuộc sống vốn đã khác biệt!"

- Ví dụ 3 – Nhà bán rẻ bất thường

Nhà chỉ 1.2 tỷ trong khu vực toàn 5–7 tỷ
→ Lý do: nhà xuống cấp, nứt móng, vướng quy hoạch
→ Giá thấp không sai, nhưng là ngoại lệ có thật

2.2 Cách xử lý

2.2.1 Giữ lại

"Không phải ngoại lệ là xấu – có những trường hợp chúng mang giá trị thông tin quan trọng."

- Ví dụ 1 – Mô hình dự đoán cho khách hàng VIP

Nếu khách hàng là người mua bất động sản hạng sang

→ Giữ lại dữ liệu biệt thự 2000 m^2, 150 tỷ để mô hình học được xu hướng riêng

2.2 Cách xử lý

2.2.1 Giữ lại

"Không phải ngoại lệ là xấu – có những trường hợp chúng mang giá trị thông tin quan trọng."

- Ví dụ 2 – Phân tích phân khúc cao cấp

Khi phân tích thị trường biệt thự, những căn giá > 100 tỷ không phải ngoại lệ mà là đối tượng nghiên cứu chính

- Ví dụ 3 – Phân tích khu vực đặc biệt

Ở khu phố cổ hoặc trung tâm TP, giá nhà rất cao dù diện tích nhỏ

→ Giữ ngoại lệ để phản ánh đúng thực tế khu vực

2.2 Cách xử lý

2.2.2 Loại bỏ

"Không xử lý ngoại lệ nguy hiểm như lái xe mà không thắt dây an toàn."

- Ví dụ 1 – Lỗi nhập diện tích = 0

Nhà có giá và mô tả đầy đủ nhưng diện tích là 0 m^2
→ Rõ ràng là nhập sai → nên loại bỏ hoặc điền lại

- Ví dụ 2 – Làm báo cáo bị méo

Trung bình giá nhà toàn TP là 40 tỷ vì 1 căn siêu đắt → báo cáo sai thực tế → nên xử lý để không gây hiểu lầm

2.2 Cách xử lý

2.2.2 Loại bỏ

"Không xử lý ngoại lệ nguy hiểm như lái xe mà không thắt dây an toàn."

- Ví dụ 3 – Ngoại lệ làm sai lệch mô hình

Một vài điểm dữ liệu giá nhà quá cao → làm mô hình Linear Regression có hệ số sai lệch hoàn toàn

→ Cần xử lý để mô hình ổn định hơn

3. Phát Hiện Ngoại Lệ

3.1 Sử dụng IQR

Interquartile Range (IQR):

- Q1 = Phân vị thứ 25%
- Q3 = Phân vị thứ 75%
- IQR = Q3 – Q1

Điểm ngoại lệ nếu:

- Nhỏ hơn Q1 – 1.5 * IQR
- Lớn hơn Q3 + 1.5 * IQR

3.1 Sử dụng IQR (Ví dụ)

Giá nhà (tỷ đồng): [2.5, 2.7, 2.8, 2.9, 3.0, 3.1, 3.2, 3.3, 3.5, 100]

Q1 (25%): 2.8
Q3 (75%): 3.3
IQR = Q3 – Q1 = 3.3 – 2.8 = 0.5

Ngưỡng dưới: Q1 – 1.5 × IQR = 2.8 – 0.75 = 2.05
Ngưỡng trên: Q3 + 1.5 × IQR = 3.3 + 0.75 = 4.05

-> Các giá trị ngoài khoảng [2.05, 4.05] là ngoại lệ
→ 100 là ngoại lệ rất rõ

3.2 Sử dụng Z-score

Công thức:

- Z = (x – mean) / std

Ý nghĩa:

- Z-score đo độ lệch chuẩn của điểm x so với trung bình.
- Nếu |Z| > 2 hoặc 3 → có thể là ngoại lệ (tùy ngưỡng chọn).

3.2 Sử dụng Z-score (Ví dụ)

Giá nhà (tỷ đồng): [2.5, 2.7, 2.9, 3.0, 3.2, 3.3, 100]

Mean = (2.5 + 2.7 + 2.9 + 3.0 + 3.2 + 3.3 + 100) / 7 ≈ 17.1

Std ≈ 36.1 (sai số do 100 kéo lệch rất lớn)

Z của 2.5 = (2.5 – 17.1) / 36.1 ≈ -0.4

Z của 100 = (100 – 17.1) / 36.1 ≈ +2.29

Z = 2.29 có thể được xem là ngoại lệ nhẹ

Nhưng do dữ liệu đã bị lệch vì chính ngoại lệ → Z-score ít tin cậy khi ngoại lệ quá mạnh

3.3 Sử dụng Boxplot

Boxplot = biểu đồ hộp:

- Thể hiện Q1, Q2 (median), Q3.
- "Râu" thể hiện phạm vi dữ liệu bình thường.
- Dấu chấm ngoài râu = ngoại lệ (tính theo IQR).

3.3 Sử dụng Boxplot (Ví dụ)

Giá nhà (tỷ đồng): [2.5, 2.7, 2.8, 3.0, 3.2, 3.3, 3.5, 100]

Mô tả Boxplot:

- Thân hộp (box): từ Q1 = 2.75 đến Q3 = 3.3
- Đường giữa: median = 3.0
- "Râu" kéo ra đến giá trị nằm trong ngưỡng hợp lý (3.5)
- Dấu chấm ngoài "râu": điểm 100 → ngoại lệ

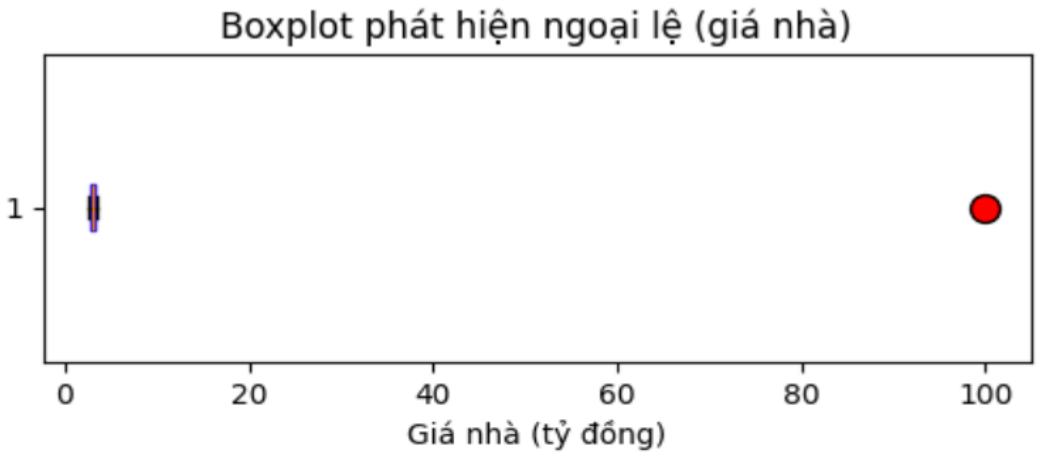

3.4 Sử dụng Scatterplot

Scatterplot = biểu đồ phân tán

- Trục X: Diện tích
- Trục Y: Giá nhà

Quan sát:

- Những điểm nằm cô lập, lạc lõng khỏi đám đông → ngoại lệ.
- Tốt để phát hiện ngoại lệ đa chiều (2 hoặc nhiều biến).

3.4 Sử dụng Scatterplot (Ví dụ)

Diện tích (m^2)	Giá (tỷ đồng)
50	2.5
60	2.8
70	3.0
80	3.2
90	3.5
100	3.8
30	100

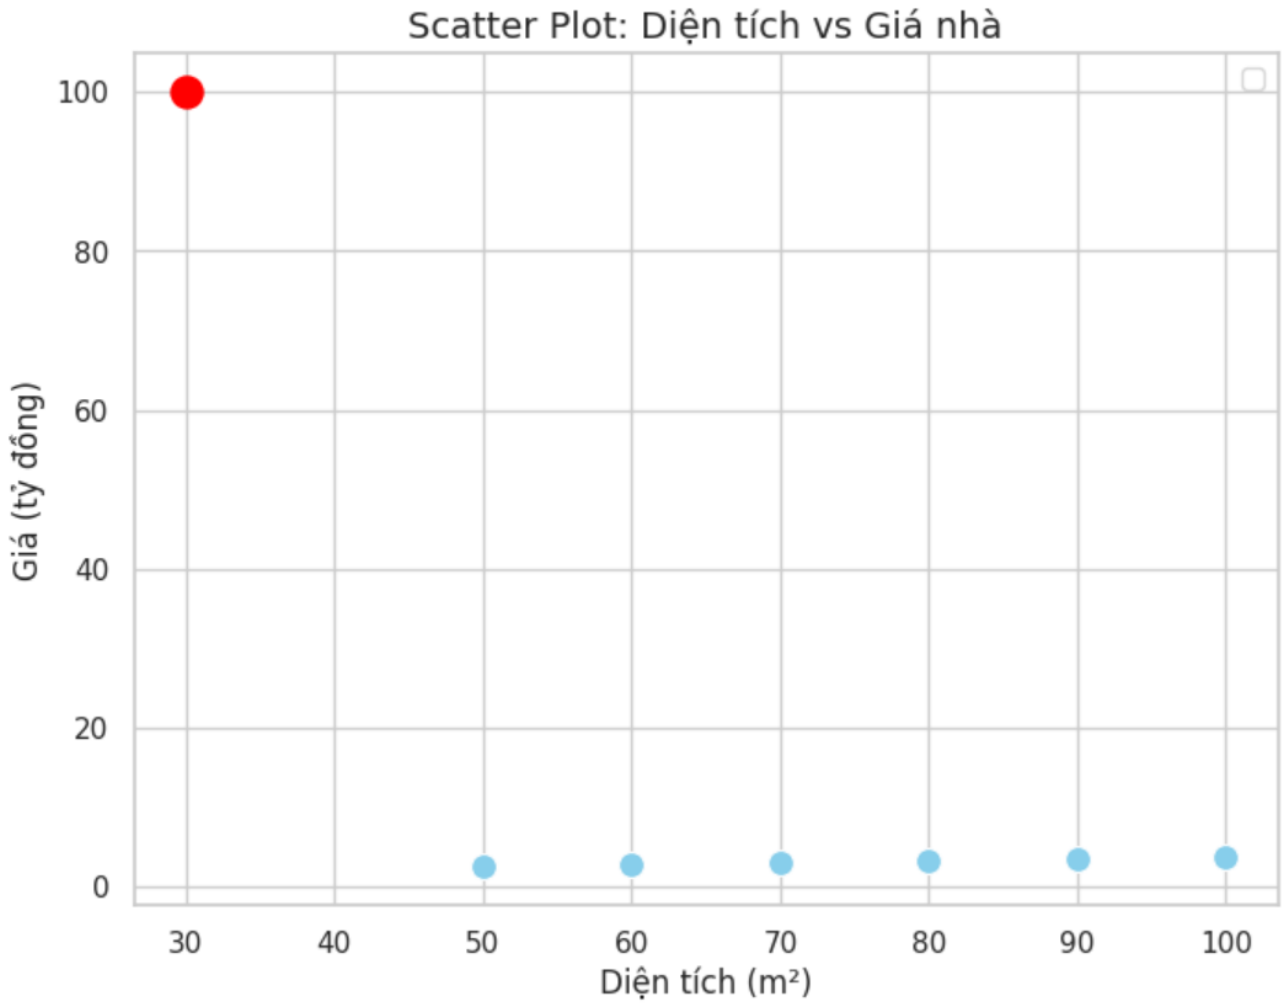

3. PHÁT HIỆN NGOẠI LỆ

Phương pháp	Ưu điểm	Nhược điểm
IQR	Dễ hiểu, không cần giả định phân phối	Phụ thuộc vào phân vị, không ổn định với dữ liệu nhỏ
Z-score	Dễ tính, phù hợp với dữ liệu chuẩn	Không hiệu quả nếu dữ liệu lệch phân phối
Boxplot	Trực quan, dễ phát hiện ngoại lệ	Khó áp dụng với nhiều chiều
Scatterplot	Hiệu quả với dữ liệu 2 chiều	Không áp dụng được nếu quá nhiều biến

4. Thực Hành Ngoại Lệ

4. THỰC HÀNH XỬ LÝ NGOẠI LỆ

```
# Thư viện cần dùng
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy import stats

# Đọc dữ liệu
df = pd.read_csv('house_prices.csv')
df.head()
```

4.1 Sử dụng IQR

👉 Tìm các giá trị "quá xa" so với phần lớn dữ liệu giá nhà.

B1: Tính Q1 (25%) và Q3 (75%) của cột Price.

B2: Tính IQR = Q3 - Q1, là vùng giá trị trung tâm của dữ liệu.

B3: Tạo ngưỡng trên/dưới bằng cách mở rộng vùng này 1.5×IQR.

B4: Các giá trị nhỏ hơn **giới hạn dưới** hoặc lớn hơn **giới hạn trên** được xem là ngoại lệ (outliers).

4.1 Sử dụng IQR

```
Q1 = df['Price'].quantile(0.25)
Q3 = df['Price'].quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

outliers_iqr = df[(df['Price'] < lower_bound) |
(df['Price'] > upper_bound)]
```

4.1 Sử dụng IQR

```
# Phát hiện ngoại lệ cho nhiều biến
cols = ['Area', 'Rooms', 'Price']

for col in cols:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR
    outliers = df[(df[col] < lower) | (df[col] > upper)]
    print(f"{col}: {len(outliers)} ngoại lệ")
```

4.2 Sử dụng Z-Score

👉 Phát hiện giá nhà bất thường so với phần còn lại của dữ liệu.

B1: Chuẩn hóa dữ liệu bằng Z-score

- Z-score = khoảng cách so với trung bình chia cho độ lệch chuẩn.
- Đo lường xem mỗi giá trị xa trung bình bao nhiêu độ lệch chuẩn.

B2: Xác định ngoại lệ

Quy ước $|Z| > 3$ → giá trị nằm rất xa trung bình → khả năng là ngoại lệ cao.

B3: Lọc các bản ghi ngoại lệ

Những giá trị vượt ngưỡng này sẽ được đánh dấu và có thể xử lý tiếp (loại bỏ, điều chỉnh, hoặc biến đổi).

4.2 Sử dụng Z-Score

```
# Tính Z-score cho Price
z = np.abs(stats.zscore(df['Price']))

# Lọc ra các ngoại lệ
outliers_z = df[z > 3]
```

4.3 Sử dụng Boxplot

👉 Nhanh chóng nhìn thấy giá trị bất thường.

B1: Chọn biến cần quan sát: Price (giá nhà)

B2: Cách Boxplot xác định ngoại lệ

- Vẽ hộp (box): từ Q1 đến Q3, vạch trung vị (median).
- Râu (whisker): thường nằm trong khoảng [Q1 - 1.5*IQR, Q3 + 1.5*IQR].
- Giá trị nằm ngoài râu → điểm ngoại lệ.

4.3 Sử dụng Boxplot

```
# Khởi tạo kích thước figure
plt.figure(figsize=(8,5))

# Vẽ Boxplot cho cột Price
sns.boxplot(x=df['Price'])

# Thêm tiêu đề
plt.title('Boxplot Giá nhà')

# Hiển thị đồ thị
plt.show()
```

4.4 Sử dụng Scatter

👉 Quan sát mối quan hệ và phát hiện bất thường

B1: Chọn cột dữ liệu cần quan sát: Area và Price.

B2: Mỗi bản ghi là một điểm trên đồ thị

- Trục X → diện tích, trục Y → giá.
- Một điểm cách xa phần lớn dữ liệu → khả năng là ngoại lệ.

B3: Kết hợp màu sắc hoặc ký hiệu (tùy chọn)

- Để highlight ngoại lệ phát hiện trước đó bằng Z-score hoặc IQR.
- Ví dụ: điểm ngoại lệ màu đỏ, dữ liệu bình thường màu xanh.

4.4 Sử dụng Scatter

```
plt.figure(figsize=(8,6))

# Vẽ scatter plot
sns.scatterplot(x='Area', y='Price', data=df)
plt.title('Scatterplot: Diện tích vs Giá')

# Nhãn trục x
plt.xlabel('Diện tích (m²)')

# Nhãn trục y
plt.ylabel('Giá nhà')
plt.show()
```

4.4 Sử dụng Scatter

```
# Ví dụ Highlight lọc ngoại lệ theo Price
outliers = df[df['Price'] > 10]

# Màu đỏ → điểm ngoại lệ
sns.scatterplot(x='Area', y='Price', data=df, color='blue')

# Màu xanh → dữ liệu bình thường
sns.scatterplot(x='Area', y='Price', data=outliers,
color='red')
```

FPT Education

FPT POLYTECHNIC

THANK YOU