FPT Education

FPT POLYTECHNIC

cdio™

Conceive Design Implement Operate

Bài 3: Xử Lý Dữ Liệu Dạng Số

www.poly.edu.vn

AGENDA

- Khái niệm chuẩn hóa
- Phương pháp xử lý
- Lựa chọn giải pháp
- Thực hành

1. Khái Niệm Chuẩn Hóa

1.1 Ví dụ dữ liệu chưa chuẩn hóa

Trong một bài toán dự đoán giá nhà, ta có hai đặc trưng:

- Diện tích (m^2): từ 50 m^2 đến 200 m^2.
- Số phòng: từ 1 đến 10 phòng.

-> Vấn đề: Nếu không chuẩn hóa, đặc trưng "diện tích" sẽ có giá trị lớn hơn rất nhiều so với "số phòng". Điều này có thể khiến mô hình học máy chú trọng quá nhiều vào diện tích, trong khi bỏ qua sự ảnh hưởng của số phòng.

1.1 Ví dụ dữ liệu chưa chuẩn hóa

Giả sử mô hình học máy đơn giản như KNN (k-nearest neighbors) được sử dụng.

Ví dụ:

- Diện tích nhà 1 = 100, diện tích nhà 2 = 150 -> Khoảng cách 50
- Số phòng nhà 1 = 3, số phòng nhà 2 = 4 -> Khoảng cách 1

-> Khoảng cách giữa diện tích (50) lớn hơn khoảng cách giữa số phòng (1) rất nhiều.

->Diện tích sẽ chiếm ưu thế lớn hơn trong việc xác định "khoảng cách" giữa các điểm

->Ảnh hưởng nhiều hơn đến kết quả dự đoán hoặc phân loại.

1.2 Hậu quả dữ liệu chưa chuẩn hóa

- **Hiệu suất mô hình giảm sút**: Mô hình học máy như KNN, SVM hoặc hồi quy tuyến tính có thể gặp khó khăn trong việc tối ưu hóa và dự đoán chính xác khi dữ liệu không đồng nhất về đơn vị và phạm vi.

- **Một đặc trưng chi phối**: Đặc trưng có giá trị lớn sẽ chi phối quá trình huấn luyện, dẫn đến mô hình thiếu chính xác hoặc không phù hợp với dữ liệu thực tế.

-> Ví dụ: Nếu dự báo giá nhà mà không chuẩn hóa dữ liệu, mô hình có thể dự đoán chính xác giá của những ngôi nhà có diện tích lớn, nhưng lại không dự đoán đúng với những ngôi nhà nhỏ.

1.3 Chuẩn hóa dữ liệu là gì?

- **Định nghĩa:** Chuẩn hóa dữ liệu là quá trình thay đổi giá trị của các đặc trưng trong dữ liệu sao cho chúng có cùng phạm vi hoặc phân phối, giúp mô hình học máy dễ dàng hơn trong việc học và tối ưu hóa.

- **Mục đích:**

- Đảm bảo công bằng giữa các đặc trưng: Tất cả các đặc trưng đều được đối xử công bằng, không có đặc trưng nào bị chi phối quá mức.
- Tăng hiệu quả huấn luyện mô hình: Dữ liệu chuẩn hóa giúp các thuật toán học máy như KNN, SVM, và hồi quy tuyến tính hội tụ nhanh và chính xác hơn.

2. Phương Pháp Chuẩn Hóa

2. PHƯƠNG PHÁP CHUẨN HÓA

Giả sử dữ liệu về diện tích và số phòng của một số ngôi nhà như sau:

Nhà	Diện tích (m^2)	Số phòng
1	50	2
2	100	4
3	150	5
4	200	6

2.1 Min-Max Scaling - Công thức

Là phương pháp đưa các giá trị của đặc trưng về phạm vi từ 0 đến 1.

Công thức chuẩn hóa là:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Trong đó:

- x là giá trị gốc của đặc trưng.
- min là giá trị nhỏ nhất của đặc trưng.
- max là giá trị lớn nhất của đặc trưng.
- x′ là giá trị đã chuẩn hóa.

2.1 Min-Max Scaling - Ví dụ

Giá trị nhỏ nhất của diện tích là **50** m^2, giá trị lớn nhất là **200** m^2.

Áp dụng công thức Min-Max cho từng giá trị diện tích:

Nhà	Diện tích (m^2)	Chuẩn hóa
1	50	(50 - 50) / (200 - 50)
2	100	(100 - 50) / (200 - 50)
3	150	(150 - 50) / (200 - 50)
4	200	(200 - 50) / (200 - 50)

2.1 Min-Max Scaling - Ví dụ

Giá trị nhỏ nhất của số phòng là **2**, giá trị lớn nhất là **6**.

Áp dụng công thức Min-Max cho từng giá trị số phòng:

Nhà	Số phòng	Chuẩn hóa
1	2	(2 - 2) / (6 - 2)
2	4	(4 - 2) / (6 - 2)
3	5	(5 - 2) / (6 - 2)
4	6	(6 - 2) / (6 - 2)

2.1 Min-Max Scaling - Ví dụ

Kết quả chuẩn hóa

Nhà	Diện tích (Chuẩn hóa)	Số phòng (Chuẩn hóa)
1	0	0
2	0.33	0.5
3	0.67	0.75
4	1	1

2.1 Min-Max Scaling - Sử dụng

- Khi dữ liệu **không có ngoại lệ quá lớn**: Min-Max hoạt động tốt khi dữ liệu phân phối đều và không có các giá trị ngoại lệ quá lớn. Các giá trị này sẽ ảnh hưởng mạnh mẽ đến quá trình chuẩn hóa.

- Khi **cần dữ liệu trong khoảng cố định**: Nếu mô hình yêu cầu dữ liệu phải nằm trong một phạm vi nhất định (ví dụ: từ 0 đến 1), Min-Max Scaling là một lựa chọn tốt.

2.2 Z-Score Normalization - Công thức

Là phương pháp chuẩn hóa dữ liệu sao cho các đặc trưng có trung bình bằng 0 và độ lệch chuẩn bằng 1

Công thức chuẩn hóa là:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

- x là giá trị gốc của đặc trưng.
- μ là giá trị trung bình của đặc trưng.
- σ là độ lệch chuẩn của đặc trưng.
- z là giá trị đã chuẩn hóa.

2.2 Z-Score Normalization - Ví dụ

Trung bình của diện tích là **125** m^2, độ lệch chuẩn là **52.91** m^2.

Áp dụng công thức Z-Score cho từng giá trị diện tích:

Nhà	Diện tích (m^2)	Chuẩn hóa
1	50	(50 - 125) / 52.91
2	100	(100 - 125) / 52.91
3	150	(150 - 125) / 52.91
4	200	(200 - 125) / 52.91

2.2 Z-Score Normalization - Ví dụ

Trung bình của số phòng là **4.25**, độ lệch chuẩn là **1.48**.

Áp dụng công thức Z-Score cho từng giá trị số phòng:

Nhà	Số phòng	Chuẩn hóa
1	2	(2 - 4.25) / 1.48
2	4	(4 - 4.25) / 1.48
3	5	(5 - 4.25) / 1.48
4	6	(6 - 4.25) / 1.48

2.2 Z-Score Normalization - Ví dụ

Kết quả chuẩn hóa

Nhà	Diện tích (Chuẩn hóa)	Số phòng (Chuẩn hóa)
1	-1.42	-1.52
2	-0.47	-0.17
3	0.47	0.51
4	1.42	1.18

2.2 Z-Score Normalization - Sử dụng

- Khi **dữ liệu có ngoại lệ**: Z-Score giúp xử lý tốt các dữ liệu có ngoại lệ, vì phương pháp này không bị ảnh hưởng mạnh bởi giá trị cực trị.

- Khi **cần phân phối chuẩn hóa quanh trung bình**: Z-Score phù hợp khi bạn cần dữ liệu phân phối chuẩn với trung bình bằng 0 và độ lệch chuẩn bằng 1.

3. Lựa Chọn Giải Pháp

3.1 So sánh Min-Max và Z-Score

Min-Max Scaling

Ưu điểm:

- Dễ hiểu và trực quan: Phương pháp này rất dễ áp dụng và dễ hiểu khi bạn muốn đưa dữ liệu về cùng một phạm vi.
- Dữ liệu trong phạm vi cố định: Giúp mô hình học máy (như KNN, Neural Networks) dễ dàng xử lý, đặc biệt khi các thuật toán yêu cầu đầu vào trong phạm vi nhất định.

Nhược điểm:

- Nhạy cảm với ngoại lệ: Min-Max rất dễ bị ảnh hưởng nếu có ngoại lệ (outliers) trong dữ liệu, vì ngoại lệ sẽ làm thay đổi giá trị min và max, dẫn đến việc chuẩn hóa không chính xác.

Ví dụ: Nếu bạn có giá trị diện tích trong phạm vi từ 50 đến 200 m^2 và có một giá trị cực lớn, chẳng hạn 1000 m^2, phương pháp Min-Max sẽ làm giảm tất cả các giá trị còn lại xuống gần 0.

3.1 So sánh Min-Max và Z-Score

Z-Score Normalization

Ưu điểm:

- Không nhạy cảm với ngoại lệ: Z-Score chuẩn hóa giúp dữ liệu không bị ảnh hưởng quá nhiều bởi ngoại lệ, vì nó dùng độ lệch chuẩn thay vì giá trị tối đa và tối thiểu.
- Phân phối chuẩn: Phù hợp cho các mô hình yêu cầu dữ liệu có phân phối chuẩn, như các mô hình hồi quy tuyến tính, logistic regression, hoặc các thuật toán tối ưu hóa như Gradient Descent.

Nhược điểm:

- Khó trực quan: Sau khi chuẩn hóa bằng Z-Score, dữ liệu có thể có giá trị âm và không nằm trong một phạm vi cố định, điều này có thể gây khó khăn khi trực quan hóa hoặc làm việc với dữ liệu.
- Không giữ được tỷ lệ ban đầu: Z-Score không giữ được tỷ lệ giữa các giá trị của đặc trưng (ví dụ, một giá trị lớn vẫn có thể chuẩn hóa về giá trị âm).

3. LỰA CHỌN GIẢI PHÁP

3.1 So sánh Min-Max và Z-Score

Min-Max Scaling:

- Thích hợp khi dữ liệu không có ngoại lệ lớn và bạn cần đưa các giá trị vào phạm vi cố định.
- Dễ áp dụng cho các thuật toán yêu cầu đầu vào trong một phạm vi xác định như KNN, Neural Networks.
- Tuyệt đối không dùng với dữ liệu có ngoại lệ lớn vì ngoại lệ sẽ làm lệch toàn bộ quá trình chuẩn hóa.

Z-Score Normalization:

- Thích hợp khi dữ liệu có ngoại lệ lớn hoặc cần phân phối chuẩn hóa quanh trung bình (mean = 0, std = 1).
- Phù hợp với các mô hình học máy như Linear Regression, Logistic Regression, SVM, PCA và các mô hình yêu cầu tính toán độ lệch chuẩn.
- Không ảnh hưởng quá nhiều bởi ngoại lệ nhưng kết quả chuẩn hóa có thể khó trực quan.

3.2 Trường hợp sử dụng

Min-Max Scaling:

- Dữ liệu không có ngoại lệ quá lớn.
- Cần đưa các đặc trưng về phạm vi cố định để mô hình học máy có thể sử dụng dễ dàng (ví dụ KNN, Neural Networks).
- Các đặc trưng có đơn vị giống nhau và bạn muốn giữ được tỷ lệ giữa chúng.

Z-Score Normalization:

- Dữ liệu có ngoại lệ lớn hoặc có sự khác biệt rất lớn giữa các giá trị.
- Bạn cần chuẩn hóa dữ liệu về một phân phối chuẩn với trung bình 0 và độ lệch chuẩn 1.
- Các mô hình học máy yêu cầu dữ liệu có phân phối chuẩn, như hồi quy tuyến tính, SVM, hoặc PCA.

3. LỰA CHỌN GIẢI PHÁP

Đặc điểm	Min-Max Scaling	Z-Score Normalization
Phạm vi dữ liệu	[0, 1] hoặc [-1, 1]	Trung bình = 0, Độ lệch chuẩn = 1
Dễ hiểu, trực quan	Có, dữ liệu trong phạm vi cố định	Khó trực quan (có thể có giá trị âm)
Phù hợp với dữ liệu có ngoại lệ	Không, dễ bị ảnh hưởng ngoại lệ	Có, ít bị ảnh hưởng bởi ngoại lệ
Ứng dụng phổ biến	KNN, Neural Networks, các mô hình cần phạm vi cố định	Linear Regression, Logistic Regression, SVM, PCA

3.3 Ví dụ - Dự báo giá nhà

Dataset 1 -> Z-Score

Nhà	Diện tích (m^2)	Số phòng	Năm xây dựng	Giá nhà (triệu VND)
1	50	2	1990	2,000
2	100	4	2000	3,500
3	150	5	2010	4,500
4	200	6	2020	6,000
5	1000	8	1995	20,000

3.3 Ví dụ - Dự báo giá nhà

Dataset 2 -> Min-Max Scaling

Nhà	Diện tích (m^2)	Số phòng	Năm xây dựng	Giá nhà (triệu VND)
1	60	2	1990	1,800
2	85	3	2000	2,200
3	100	3	2010	2,700
4	120	4	2015	3,000
5	150	4	2020	3,600

3.3 Ví dụ - Dự báo giá nhà

Dataset 3 -> ???

Nhà	Diện tích (m^2)	Số phòng	Năm xây dựng	Giá nhà (triệu VND)
1	50	1	1990	1,200
2	75	2	2000	1,800
3	80	2	2005	2,200
4	200	6	2010	10,000
5	500	10	2015	50,000

3.3 Ví dụ - Dự báo chất lượng không khí

Dataset 4 - > Min-Max Scaling

Ngày	PM2.5 (µg/m³)	PM10 (µg/m³)	CO (ppm)	NO2 (ppb)	SO2 (ppb)
2025-10-01	25	45	0.5	30	5
2025-10-02	28	50	0.6	32	6
2025-10-03	30	55	0.7	35	7
2025-10-04	22	40	0.4	28	4
2025-10-05	27	48	0.5	33	6

3.3 Ví dụ - Dự báo chất lượng không khí

Dataset 5 -> Z-Score

Ngày	PM2.5 (µg/m³)	PM10 (µg/m³)	CO (ppm)	NO2 (ppb)	SO2 (ppb)
2025-10-01	25	45	0.5	30	5
2025-10-02	28	50	0.6	32	6
2025-10-03	30	55	0.7	35	7
2025-10-04	22	40	0.4	28	4
2025-10-05	500	800	20	300	100

3.3 Ví dụ - Dự báo chất lượng không khí

Dataset 6 -> ???

Ngày	PM2.5 (µg/m³)	PM10 (µg/m³)	CO (ppm)	NO2 (ppb)	SO2 (ppb)
2025-10-01	5	10	0.2	15	2
2025-10-02	15	25	0.3	20	4
2025-10-03	200	300	3.0	150	50
2025-10-04	50	75	1.0	40	10
2025-10-05	100	150	2.5	120	30

4. Thực Hành Chuẩn Hóa

4. THỰC HÀNH CHUẨN HÓA

```
import pandas as pd

# Đọc dữ liệu
df = pd.read_csv('house_prices.csv')
df.head()

# Quan sát dữ liệu để biết min, max, trung bình,
độ lệch chuẩn.
df[['Area','Price']].describe()
```

4.1 Sử dụng Min-Max Scaling

B1: Khởi tạo scaler bằng MinMaxScaler() của sklearn.

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
```

B2: Áp dụng fit_transform() lên các cột cần chuẩn hóa

```
tf = scaler.fit_transform(df[['Area','Price']])
```

B3: Lưu kết quả vào các cột mới để giữ dữ liệu gốc.

```
df[['Area_scaled','Price_scaled']] = tf
```

4.2 Sử dụng Z-Score

B1: Khởi tạo scaler bằng StandardScaler() của sklearn.

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
```

B2: Áp dụng fit_transform() lên các cột cần chuẩn hóa

```
tf = scaler.fit_transform(df[['Area','Price']])
```

B3: Lưu kết quả vào các cột mới để giữ dữ liệu gốc.

```
df[['Area_z','Price_z']] = tf
```

4.3 So sánh sự thay đổi

```
import matplotlib.pyplot as plt
fig, axes = plt.subplots(1,3, figsize=(15,4))

# Dữ liệu gốc
axes[0].hist(df['Price'], bins=10, color='blue', alpha=0.7)
axes[0].set_title('Price gốc')

# Min-Max Scaling
axes[1].hist(df['Price_scaled'], bins=10, color='green', alpha=0.7)
axes[1].set_title('Price Min-Max')

# Z-Score
axes[2].hist(df['Price_z'], bins=10, color='red', alpha=0.7)
axes[2].set_title('Price Z-Score')
```

4.3 So sánh sự thay đổi

-> Phân bố không thay đổi nhưng đơn vị khác.

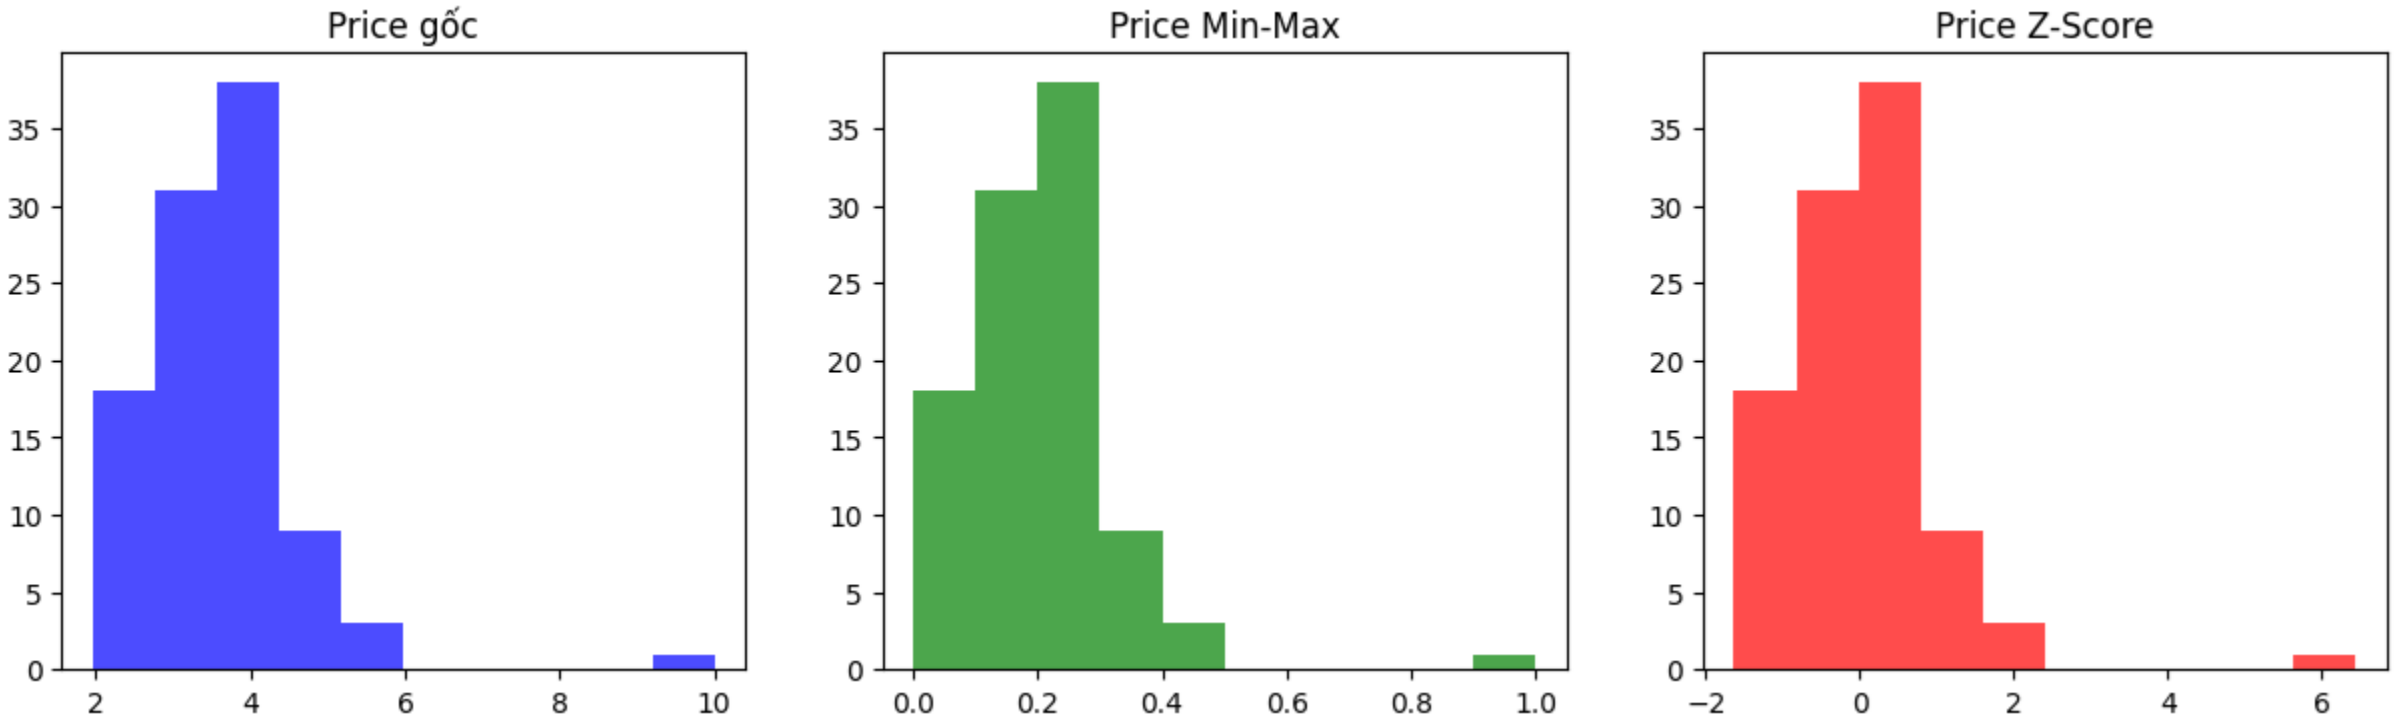

4. THỰC HÀNH CHUẨN HÓA

4.3 So sánh sự thay đổi

```python
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import numpy as np

# --- Load dataset ---
df = pd.read_csv('house_prices.csv')
X = df[['Area', 'Rooms']]
y = df['Price']

# --- Chia train/test ---
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# --- Linear Regression chưa chuẩn hóa ---
model_raw = LinearRegression().fit(X_train, y_train)
y_pred_raw = model_raw.predict(X_test)

print("Chưa chuẩn hóa:")
print("Hệ số hồi quy:", model_raw.coef_)
print("Intercept:", model_raw.intercept_)
print("R²:", r2_score(y_test, y_pred_raw))
print("MSE:", mean_squared_error(y_test, y_pred_raw))

# --- Biểu đồ hệ số hồi quy ---
features = ['Area', 'Rooms']
coef_raw = model_raw.coef_
x = np.arange(len(features))

plt.figure(figsize=(6,4))
plt.bar(x, coef_raw, color='skyblue')
plt.xticks(x, features)
plt.ylabel('Hệ số hồi quy')
plt.title('Hệ số hồi quy - Chưa chuẩn hóa')
plt.show()
```

```python
from sklearn.preprocessing import StandardScaler  # Hoặc MinMaxScaler

# --- Chuẩn hóa ---
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# --- Chia train/test sau chuẩn hóa ---
X_train_s, X_test_s, y_train_s, y_test_s = \
         train_test_split(X_scaled, y, test_size=0.2, random_state=42)

# --- Linear Regression sau chuẩn hóa ---
model_scaled = LinearRegression().fit(X_train_s, y_train_s)
y_pred_scaled = model_scaled.predict(X_test_s)

print("\nSau chuẩn hóa:")
print("Hệ số hồi quy:", model_scaled.coef_)
print("Intercept:", model_scaled.intercept_)
print("R²:", r2_score(y_test_s, y_pred_scaled))
print("MSE:", mean_squared_error(y_test_s, y_pred_scaled))

# --- Biểu đồ hệ số hồi quy ---
coef_scaled = model_scaled.coef_
x = np.arange(len(features))

plt.figure(figsize=(6,4))
plt.bar(x, coef_scaled, color='salmon')
plt.xticks(x, features)
plt.ylabel('Hệ số hồi quy')
plt.title('Hệ số hồi quy - Sau chuẩn hóa')
plt.show()
```

4.3 So sánh sự thay đổi

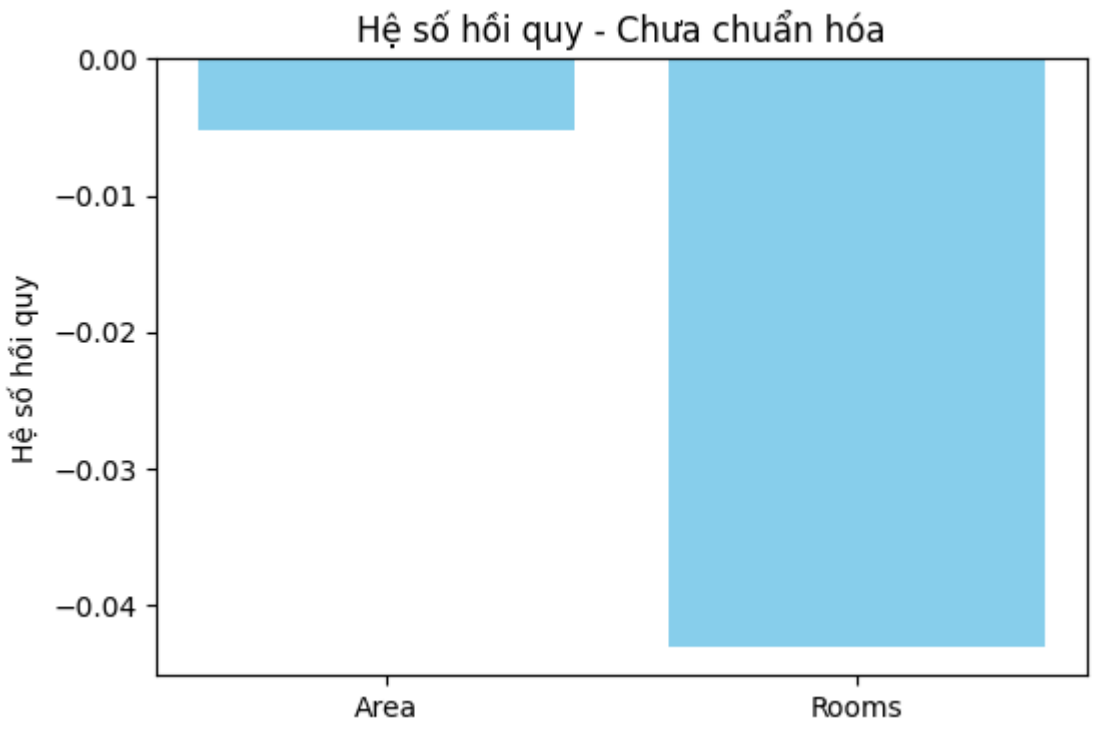

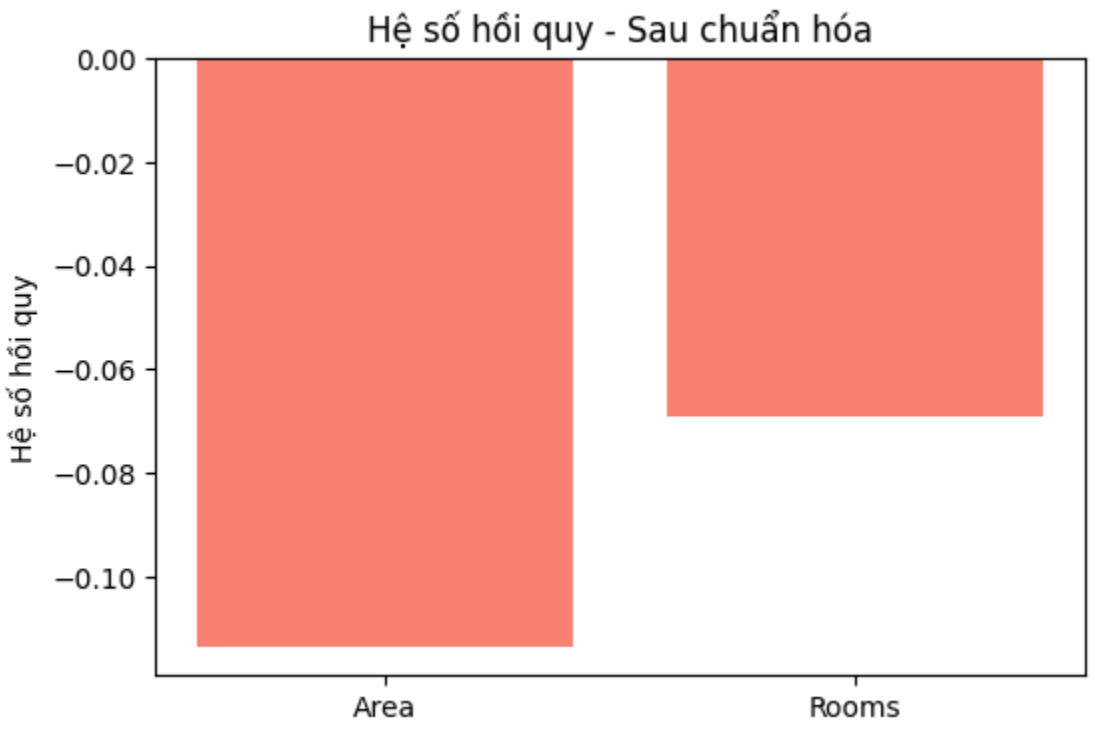

FPT Education

FPT POLYTECHNIC

THANK YOU